

基于 Word2vec 的二语教学“基本形式库” 构建方法初探

杨苛鑫 庄会彬 山东大学文化传播学院

杨 牧 浙江大学外国语学院

摘 要 二语教学中,重视表达取向的“基本形式”观致力于构建一个“基本形式库”。本文以微博语料库为例,将其中高频词设置为检索词,依据 Word2vec 训练的词向量进行检索,围绕检索词查找近似词来构成(准)等义组,继而进一步确定该组的“基本形式”。本文初步提出了一种兼具可操作性和效率性的建设方法,作为人工建设“基本形式库”的辅助工具,并检索出了一部分基本形式(准)等义组作为前人研究的补充,为“基本形式”观理论进一步发展提供工具与思考。

关键词 基本形式 Word2vec 词向量 (准)等义组

DOI: 10.3696/j.issn.2095-798X.2024.03.009

一、引言

郭继懋、陈爱锋(2016)基于功能语言学理念提出了“基本形式”的概念:“基本形式指外语学习者为了能在日常生活中成功表达自己的思想意愿而需要掌握的语言形式,包括有独特功能的语言形式和多个等义形式中用法最全面、使用范围最广、最容易用的那个语言形式。”该文将“基本形式”分为“一对一”和“一对多”两种,前者是一个功能对应一个形式,后者是一个功能对应多种形式,后者的“基本形式”需要从几个对应的“等义形式”中选择“用法最全面、使用范围最广、最容易用的”,将其确定为“基本形式”。

后续的研究中,陈爱锋、郭继懋(2021)提出了一套“基本副词”的选择标准,即借助辞书释义和替换法来确定“等义组”,在“等义组”中选择“用法限制较少、使用频率高、使用度广、语体通用性强、复杂度低的”词语,作为该“等义组”中的基本形式。该文还以“一起、一块儿”“居然、竟然、竟”为例,具体说明了基本副词的选择标准和程序。

综合以上研究,我们认为对“基本形式”的研究是有必要的,如果能构建一个较大的“基本形式库”,可以在很大程度上降低二语学习者的学习难度,但以上两篇文章在确定“基本形式”时,存在两个无法避免的问题:(1)确定“等义组”时,辞书释义法和替换法效率较低,且替换法依赖于研究者的语感,这具有较强的主观性;(2)主观地确定“等义组”之后,确定组中基本形式时同样缺乏客观标准。

我们构拟了一种构建基本形式库的方法,即先确定一部分“检索词”,然后使用“搜索引擎”找到与检索词功能相近的词并组成等义组,再在等义组中确定基本形式。这一方法将显著提高效率,使较大规模的“基本形式库”的构建成为可能。为此,我们事先需要解决两个问题:(1)如何确定“检索词”? (2)如何构建“搜索引擎”? 下文将利用词频统计与自然语言处理领域的 Word2vec 词向量训练工具,以并列连词和

表示“程度高”的程度副词为例,尝试实现这一构想,并论述使用基本形式库构建方法的优点与不足,使用这一方法检索构建基本形式等义组^①,作为此类研究的探索与尝试。

二、确定检索词并构建搜索引擎

基本形式的定义为“多个等义形式”中“用法最全面、使用范围最广、最容易用的那个语言形式”(郭继懋、陈爱锋,2016),其中,“用法最全面、使用范围最广”可以理解为在不同语体中分布形式最广且词频最高的;“最容易用的”则需要从教学角度出发,综合词型辨认、书写和学习者习得的难度来分析。我们在确定等义组时先确定“检索词”,是为了最大程度减轻前期所需要的人力,以提高效率,为此我们选择了语体和词频作为确定检索词的因素,将在特定语体中词频最高的词作为检索词。

我们选择使用的是 Word2vec 词向量训练工具在特定语体语料库中构建“搜索引擎”。Word2vec 是谷歌(Google)公司在2013年开放的一款用于训练词向量的软件工具,它可以根据自建语料库,通过优化后的训练模型快速地将一个词语表达成向量^②。通过计算不同词语向量之间的相似度,来找到与之分布相似的词。

Word2vec 只是获得词向量的一种训练工具,而词向量背后的语言学原理则是分布语义学,即弗斯(Firth)所说的“You shall know a word by the company it keep”(Palmer, 1968)。

举例来说:

桌子上有一瓶 X。

比起白酒我更喜欢喝 X。

法国产的 X 质量更好。

即使我们不知道 X 表示什么意义,也能通过上下文来猜到可能是“红酒”。而“词向量”就是计算机认识“词”的一种方式,它将某个词的上下文作为这个词的特征。我们使用的是 Word2vec 词向量的 Skip-Gram 计算方式,它的原理简单来说就是让计算机使用中心词来“猜”上下文词。

词向量工具的设计最初是为了服务于自然语言处理领域,以便于完成情感分析(彭晓彬,2016;王仁武等,2017;蔡庆平、马海群,2020)和文本分类(马思丹、刘东苏,2019;牛雪莹、赵恩莹,2019)。一些学者将词向量工具运用到了语言研究(冯志伟,2019),尤其是类型学研究(彭晓娅、周栋,2020;胡楠等,2022;施建军、周瓴,2023;施建军等,2023)。我们认为词向量工具在二语教学领域也会有较大的应用空间。

三、确定等义组

本文使用的是北京理工大学 NLPir 实验室分享的语料库资源中的 NLPir 微博内容语料库^③,共计 23 万条数据。需要说明的是,从词频出发选择“基本形式”会有较大影响。本文曾对复旦文本分类语料库进行词频统计,由于其中新闻、公告等较为正式的文本占比较大,一些形式动词(如“进行”)词频较高,对初、中级二语学习者来说,语言应用场景首先是日常交流而非公文写作,形式动词并不是他们学习的重点。因

① 郭继懋、陈爱锋(2016)和陈爱锋、郭继懋(2021)已经做出了一部分基本形式库,本文不再对此重复研究,仅作补充。

② 向量是具有方向与大小的量。

③ 该语料库由北京理工大学网络搜索挖掘与安全实验室张华平博士,通过从新浪微博、腾讯微博中公开采集与抽取获得,网址: <http://www.nlpir.org/wordpress>。

此，本文选取了更偏向口语化的微博语料进行词频统计与词向量分析。

还需要说明的是，微博语料库的语料相较于其他语料“更贴近”口语，但并不等同于口语，一方面它不能完全排除一些十分书面的表达，另一方面即使纯口语的表达也无法兼顾初、中级学习者各方面的学习要求。对于前一种情况，只要语料库规模足够大，小规模的书面对语料不会影响到算法学习到的词汇语义信息；对于后一种情况，则需要专门构建一个语料难度等级匹配、涵盖各类语体语料的语料库。对此我们会另撰文详细阐述语料库建设问题，本文旨在对检索方法可行性进行初探。

3.1 并列连词等义组的检索与分析

3.1.1 基于词频统计确定并列连词的“检索词”

我们将微博内容语料库中连词出现的频率整理在表 1 内。

表 1 并列连词词频统计										单位：次
连词	和	与	而	并	或	及	跟	而且	同	并且
频率	53 277	20 220	14 101	11 971	7 472	4 836	3 979	2 163	931	770

郭继懋、陈爱锋（2016）已经列举出了一些（准）等义组^①，例如“和、跟、同、与”列为一个（准）等义组，从词频统计上来看，“和”“与”的使用频率要远高于“跟”“同”。我们以“和”为例，来进行词向量的相似度的分析，这里选用 Skip-Gram 模式，向量维度（vector size）设置为 100，窗口大小设置为 5，排除无关词语，得到与“和”相似度较高的连词，见表 2。

表 2 不同连词与连词“和”的相似度 ^②					
连词	与	以及	及	及其	跟
相似度	0.66	0.64	0.56	0.53	0.52

从这里我们可以看出，与“和”相似度最强的是“与”“以及”“及”“及其”“跟”。我们再将和另一个高频连词“与”相似度较高的连词列在表 3。

表 3 不同连词与连词“与”的相似度			
连词	和	跟	及其
相似度	0.66	0.58	0.51

根据表 1 和表 2，我们发现“和”“跟”“与”三个词的相似度较高。这里需要基于词向量的原理解释两个问题：（1）为什么“同”与这三个连词的相似度较低？（2）如何处理相似词语中出现的“及”“以及”“及其”等词？

3.1.2 “同”与其他并列连词相似度较低

由于词向量是基于文本上下文来计算的，如果两个词的上下文高度相似，计算机就会认为这两个词高度

① 陈爱锋、郭继懋（2021）将“等义组”解释为“词语的意义、用法完全相同”，“准等义组”解释为“词语的意义、用法大部分相同”，在我们的研究方法中，初筛时未作区别。

② 由于我们的语料库相对较小，所以计算相似度得到的数值一般小于 0.8。本文主要是为了论述研究方法，后文的“基本形式库”会选用基于更大规模语料得到的模型来计算。此处与下文的数据均保留两位小数，不再另作说明。

相似，也就是前文所说的词向量所依据的语言学原理是分布语义学理论。而我们在语料中也可以发现，“同”作为连词，很多情况下不能被“和”“跟”替换，如以下几个例子：

- (1) 王毅同美国总统国家安全事务助理沙利文举行会晤（新华网文章标题，2023年5月11日）
- (2) ? 王毅和美国总统国家安全事务助理沙利文举行会晤
- (3) 外交部同联合国驻华机构共商推进全球发展倡议（《人民日报》2021年12月10日03版）
- (4) ? 外交部跟联合国驻华机构共商推进全球发展倡议

例(1)(3)来自新闻标题，例(2)(4)是本文将“同”替换为“和”“跟”之后的例句。从例句中可以看出，很多正式的书面语体只能使用“同”而不能使用“和”“跟”，这导致了“同”与“和”“跟”的上下文很少有相同的情况，在词向量的计算中相似度也就较低。这与用替换法确定等义组（陈爱锋、郭继懋，2021）的原理是相同的，考察两个词是否能在句子中相互替换，本质上是看两个词能否有相同的分布环境。由于汉语教师或辞书编写者不可能穷举两个词的分布环境，仅凭经验确定等义组就会出现这样的情况：有的分布环境可以替换，有的分布环境又不能替换，是否将这两个词归为同一等义组就需要依靠研究者的经验和语感。我们使用词向量计算出相似度，则可以规定只选择相似度大于0.5的进入考虑范围，减少筛选等义组过程中的工作量。

3.1.3 对“及”“以及”“及其”等词的处理

我们在研究中发现，“及”“以及”“及其”等词与“和”“跟”“与”相似度较强，但吕叔湘在《现代汉语八百词》（增订本）中指出，“及”“以及”均多用于书面，但我们发现有些情况下的“及”可以替换为“和”，例如：

- (5) 拖拉机、收割机以及各种小农具。（吕叔湘，1999：615）
- (6) 人员、图书、仪器及其他。（吕叔湘，1999：286）

例(5)(6)中“及”完全可以替换成“和”。“及”“以及”虽然也多用于书面，但不同的是，正是因为使用了“及”“以及”，整个句子才带有书面语意味，将其替换为“和”后，句子就失去了书面语意味，变得口语化了。而“同”作为连词，只能用于很正式的书面语中。也就是说，“及”“以及”使上下文具有书面语意味，“同”则是被限制在很正式的书面语环境中，所以“和”与“及”“以及”相似度高，而“和”“同”相似度弱。

对于“及”“以及”这类带有“使句子具有书面语意味”功能的并列连词，我们认为不宜将其与“和”“与”归为同一（准）等义组。除此之外，“及其”表示“和他（他们）的”，分布上与“和”“与”相似度较高，但也不宜与之归为同一（准）等义组，我们在筛选连词等义组时仅凭语感就可以将这类词筛选出来，不再赘述。

3.1.4 检索中出现的无关词语

我们在计算跟“与”相似度强的词时得到一些无关词语，它们和“与”的相似度也较强，例如“对话（0.60）”“合作（0.59）”“无关（0.57）”。这并非我们的方法有问题，而是词向量计算的原理导致的。Skip-Gram在训练流程中需要根据中心词预测上下文词，由于“与”和“对话”“合作”有相同的上下文，例如：

- (7) 中国将重点在四方面推进与中亚国家经贸合作（中工网新闻标题，2023-05-26）
- (8) 委内瑞拉政府宣布将与反对派重启对话（《人民日报》文章标题，2019-07-09）

假设窗口大小设置为3，例(7)中“与”的上下文是“四、方面、推进”和“中亚、国家、经贸”，而“合作”的上下文是“中亚、国家、经贸”，两个词的上下文是很相似的，所以计算机经过计算就会得出两者的相似度较高。

使用计算机基于分布地去寻找（准）等义组，能高效地找到“和”“跟”这种绝大多数语境能够互换的连词，也会输出这种高频率“共享”语境的词，但这类无关词语不需借助辞书就可以辨别出来，它对利用词向量筛选基本形式（准）等义组产生的影响较小。

3.2 表示“程度高”的副词等义组的检索与分析

程度副词是使用频率很高的一类副词，有学者统计过，在《汉语教程（第三册·上）》（杨寄洲，1999）三四百字的课文中，“程度副词的出现率约为30%，也就是说平均每3～4句话中，就会有一个程度副词出现”（张珩，2005）。我们使用python的jieba库^①分词并标注词性，对语料库中的副词进行词频统计，其中表“程度高”义的副词词频如表4所示。

表4 表“程度高”义的副词词频单位：次

副词	很	非常	特别	真是	相当
词频	7 563	2 341	2 323	2 109	586

需要说明的是，这里检索词的选择主要依据词频，但仍然需要研究者的语感和经验的参与。所有表示程度的副词中，“最”的频率最高，出现了12 362次，但我们认为不宜将其放在“程度高”的等义组中，因为从功能角度来说，“最”指称的事物一般是唯一的（“最高的建筑”在特定语境中是唯一的），而“很”“非常”“特别”指称的事物却并不唯一（“很高的建筑”在语境中可以有多个），两者在表达功能上有显著差异，因此表4中没有“最”。

以高频词为检索词，我们将与“很”“非常”“特别”三个词相似度高的副词整理如表5。

表5 与“很”相似度高的副词

“很”与其他词	相似度数值	“非常”与其他词	相似度数值	“特别”与其他词	相似度数值
非常	0.76	很	0.76	比较	0.60
挺	0.67	比较	0.71	非常	0.60
比较	0.66	十分	0.69	相当	0.58
有点	0.60	相当	0.65	尤其	0.58
真	0.59	特别	0.60	很	0.53
十分	0.59	多么	0.56		
相当	0.57	最	0.56		

凭借语感，显然“比较”“有点”不能表示“程度高”，故将其筛出。其次，我们发现“非常”组中出现的“很”“十分”“相当”在“很”组也出现了，“特别”组出现的“非常”“相当”“很”在“非常”组中也出现了。三组词每两组找出共现的词，我们就可以得到一个表示“程度高”的程度副词的（准）等义组，即“很、非常、特别、十分、相当”。

① 详见jieba库，网址：<https://github.com/fxsjy/jieba>。

四、确定基本形式

前文的研究主要是将语料库中的高频词作为检索词，检索得到等义组，下一步是确定等义组中的“基本形式”。根据陈爱锋、郭继懋（2021）的标准无法通过简单的检索来确定，我们同样基于语料库的方式提出一些尝试与探索。

如果一个词在口语和书面语等各种语体中都可以使用，就可以被认为是“使用度广、语体通用性强”。这里我们选取了与微博语料库（1 663 万字）字数基本相当的新闻语料库（1 545 万字），分别统计前文获得的表“程度高”义副词（准）等义组中每个词的词频，结果如表 6 所示。

表 6 表“程度高”义副词（准）等义组中词的词频

表“程度高”义副词	很	非常	特别	相当	十分
在新闻语料库中的词频	4 528	3 279	2 999	1 330	1 290
在微博语料库中的词频	7 563	2 341	2 323	586	633

从表 6 中可以看出，副词“很”“非常”“特别”在新闻语料库与微博语料库中都属于高频词，但“相当”和“十分”在微博语料库中的词频远低于新闻语料库，这可以说明“相当”和“十分”的“使用广度”和“语体通用性”是较差的，不宜作为基本形式。

如果一个词在不同语体都被高频使用，则可以认为这个词是“使用度广、语体通用性强”的，也必然不属于某一领域需要专业知识才能理解的“复杂词/术语”，但是否属于二语教学中的“易学、容易掌握的”，仍然需要研究者基于经验来进一步判断。

总的来说，分语料库进行词频统计的方式不是确定基本形式的唯一标准，但能够从数据层面给出参考，辞书、研究者的语感与经验仍然是判断基本形式的首要标准，相关方法在陈爱锋、郭继懋（2021）的研究中已有论述，但分语体统计得到的词频作为重要参考依据，也应该被重视。

五、余论

最后我们需要对以下三个问题进一步说明。

第一，“基本形式”仍处于理论发展期，目前研究范围主要局限在虚词，既然基本形式指“需要掌握的语言形式”，其研究必然不能只限于虚词。是否需要通过近义词辨析来确定实词中的基本形式，以及如何判断不同构式的基本形式，乃至不同句型的基本形式，都是需要进一步讨论的议题。

第二，我们提倡“数据驱动的二语教学研究”，其主体首先是二语教学研究，数据是辅助教师和研究者提高效率的工具，数据也有其局限性。Word2vec 等词向量训练工具并不能理解一个词具有多个义项的问题，机器只能先分词，再将词处理为词例（token）来学习词的分布。例如，机器只能将句子中的“而”作为一个词来学习分布，不能将“而”区分成“表并列的”和“表转折的”分别学习分布，最终还是要以语言学研究者的语感为准。

第三，在分语体词频统计时，我们简单地将微博语料当作口语语料，实际上还需要一个由适合初、中级学习者文本构建成的“通用语料库”，以适应不同水平的学习者的综合需求。

综上，本文使用 Word2vec 词向量训练工具在特定语料库中检索近义词，确定等义组的基本形式（详见

附录),这一方法最大的优点是效率高,能在较短的时间内训练出词向量并辅助检索等义组。另一个优点则是可以根据特定的语料库进行定制,在未来的研究中,可以进一步细分出小说故事中的基本形式、商务交际中的基本形式,帮助学习者在短时间内有针对性地对某一领域的汉语表达“快速入门”。

本文的目的是希望将词向量工具引入基本形式的研究中,未来会进一步完善研究中数据规模较小、词与词之间相似度差异不够显著等问题。作为基本形式库构建方法的初探,也希望可以抛砖引玉,引起其他学者对“基本形式”理论和词向量工具的重视,以期未来出现更多相关研究。

附录

使用 Word2vec 词向量工具构建的汉语教学“基本形式”等义组^①

(一) 副词

1. 程度副词:

[很、非常、特别、十分、相当]

[更、更加、越来越]

[稍微、稍稍、稍、略微、略]

[格外、分外][较、比较]

2. 范围副词:

[都、全都]

[只、仅]

[一概、一律、统统]

[凡是、但凡]

3. 时间副词:

[刚、刚刚]

[立刻、马上、立即、立马、当即]

[赶紧、急忙、连忙、赶忙、赶快]

[顿时、立时][从来、压根儿]

[一直、始终、长年]

[经常、时常、常常、常]

[往往、常常、通常、多半]

[偶尔、有时、有时候]

[向来、一向、素来]

4. 语气副词:

[也许、或许]

[大约、约、大概]

^① 这里参考了 github 开源项目 Synonyms (v3.18.0) 基于中文维基百科训练的词向量模型(网址: <https://github.com/chatopera/Synonyms>),并对检索出的词语参考词典和专家语感进行了人工筛选。我们的处理是通过高频词作为检索词,输出近似词,初筛后组成等义组。

[果然、果真、果不其然]
 [未必、不见得]
 [不必、不用、无须、无需]
 [多半、大多、大都]
 [兴许、说不定、没准]
 [尽量、尽可能]
 [究竟、到底]
 [的确、确实]

(二) 连词

[即使、即便、就算]
 [但、但是、可是]
 [依然、依旧]
 [因此、故此、因而、故而]
 [由于、鉴于]
 [进而、从而、继而]

参考文献

- 蔡庆平, 马海群. 基于 Word2Vec 和 CNN 的产品评论细粒度情感分析模型 [J]. 图书情报工作, 2020 (6): 49-58.
- 陈爱锋, 郭继懋. 二语表达取向“基本形式”观下的“基本副词”选择研究 [J]. 国际汉语教学研究, 2021 (1): 68-78.
- 冯志伟. 词向量及其在自然语言处理中的应用 [J]. 外语电化教学, 2019 (1): 3-11.
- 郭继懋, 陈爱锋. 二语教学应该重视表达取向的“基本形式”观 [J]. 语言教学与研究, 2016 (6): 12-18.
- 胡楠, 张文强, 胡韧奋. 基于跨语言对齐词向量的汉日词汇意义比较研究 [J]. 语言文字应用, 2022 (2): 133-143.
- 吕叔湘. 现代汉语八百词 (增订本) [M]. 北京: 商务印书馆, 1999.
- 马思丹, 刘东苏. 基于加权 Word2vec 的文本分类方法研究 [J]. 情报科学, 2019 (11): 38-42.
- 牛雪莹, 赵恩莹. 基于 Word2Vec 的微博文本分类研究 [J]. 计算机系统应用, 2019 (8): 256-261.
- 彭晓彬. 基于 word2vec 的文本情感分析方法研究 [J]. 网络安全技术与应用, 2016 (7): 58-59.
- 彭晓娅, 周栋. 跨语言词向量研究综述 [J]. 中文信息学报, 2020 (2): 1-15.
- 施建军, 刘磊, 周瓴. 基于词向量的汉日通用汉字词语义计量研究方法探索 [J]. 外语教学理论与实践, 2023 (1): 18-36.
- 施建军, 周瓴. 基于词向量的汉语“N 的 V”结构研究——兼与日语「N の V」结构比较 [J]. 外语电化教学, 2023 (2): 71-77.
- 王仁武, 宋家怡, 陈川宝. 基于 Word2vec 的情感分析在品牌认知中的应用研究 [J]. 图书情报工作, 2017 (22): 6-12.
- 杨寄洲. 汉语教程 (第三册·上) [M]. 北京: 北京语言文化大学出版社, 1999.
- 张珩. 留学生使用程度副词时的常见偏误类型及原因分析 [J]. 语文学刊, 2005 (21): 13-17.
- PALMER F R. *Selected Papers of J.R.Firth 1952-1959* [M]. London: Longmans, 1968: 168-205.

Construction of a “Basic Form Corpus” for TCSOL Based on Word2vec

YANG Kexin¹, ZHUANG Huibin¹, YANG Mu²

School of Culture and Communication, Shandong University¹,

School of International Studies, Zhejiang University²

Abstract

In second language teaching, the “Basic Forms” concept, which emphasizes semantic expression, aims to construct a “Basic Form Corpus”. Taking the Weibo corpus as an example, this paper sets high-frequency words as search items and employs Word2vec-trained word vectors for retrieval. The (quasi-)synonym group is formed by searching for synonyms related to search items, further establishing the “Basic Forms” of the group. The paper proposes a preliminary method that combines operability and efficiency. As an auxiliary tool for constructing the “Basic Form Corpus”, a subset of the basic form (quasi-)synonym group is retrieved to supplement previous studies, offering some suggestions for further research of the “Basic Form” approach.

Keyword

Basic Form; Word2vec; word vector; (quasi-)synonym corpus

作者简介

杨苛鑫, 山东大学文化传播学院在读博士研究生。主要研究方向为汉语句法学, 计量语言学。

庄会彬(通信作者), 山东大学文化传播学院语言学及应用语言学专业教授、博导。主要研究方向为形式语言学、历史语言学、语言教育。

杨牧, 浙江大学外国语学院在读博士研究生。主要研究方向为计量语言学。