

数据驱动的汉语动名兼类探索 *

杨 牧¹ 刘海涛²

(1. 浙江大学外国语学院 浙江 杭州 310058; 2. 复旦大学外国语学院 上海 200433)

〔摘要〕“名动包含说”引发了汉语词类格局的大讨论。动名如何布局仍莫衷一是，但其语义关系逐渐得到重视。动名义义，异中有同，难以用传统理论、方法准确把握。本文结合用法论和数据驱动范式，构建了动 / 名词及其兼类词的向量，经专家知识、词典标注、参照词向量等检验后，分析了动名关系的宏观模式。结果显示，动词和名词涌现出偏向于动词的连续统模式。以上探索表明，数据驱动不仅有助于动名研究，还能为数智时代的语言学研究转型提供参考。

〔关键词〕动名兼类；用法论；词向量；数据驱动；连续统

〔中图分类号〕H146〔文献标识码〕A〔文章编号〕1003-5397(2025)03-0089-14

DOI:10.16499/j.cnki.1003-5397.2025.03.015

Toward a Data-Driven Exploration of Verbo-Nominal Ambiguity in Chinese

YANG Mu, LIU Haitao

Abstract: The "Noun-Verb Inclusion Hypothesis" has triggered extensive discussions on the categorical architecture of word classes in Chinese. Although no consensus has been reached regarding the categorical distribution of verbs and nouns, their semantic relationships have gradually gained scholarly attention. Traditional theories and methodologies struggle to accurately capture the nuanced similarities and differences in the semantics of verbs and nouns. This study integrates usage-based theory with a data-driven paradigm to construct word vectors for verbs, nouns, and verbo-nominal ambivalent words. Following validation through expert knowledge, dictionary annotations, and reference word vectors, it analyzes the macro-level patterns of verb-noun relationships. The results indicate that verbs and nouns emerge as forming a continuum with a preference toward verbs. This exploration suggests that data-driven approaches not only contribute to research on noun-verb relationships, but also offer valuable insights for the transformation of linguistic studies in the era of digital intelligence.

Keywords: verbo-nominal ambiguity; usage-based theory; word vectors; data-driven approach; continuum

〔收稿日期〕2025-02-15

〔作者简介〕杨牧，浙江大学外国语学院博士研究生，主要研究数据驱动语言学和语言复杂网络；刘海涛（通讯作者），复旦大学外国语言文学学院文科资深教授，博士，博士生导师，主要研究数据驱动语言学、数字人文、依存语法和语言规划。

* 本研究系复旦大学“数字人文和语言计量实验室”研究成果，研究中得到教育部人文社会科学重点研究基地重大项目“数据驱动的外语能力发展研究”（22JJD740018）的资助。

一 引言

在汉语中,动词和名词是数量最多、使用最频繁的两大词类。然而,现代汉语没有发达的形态,难以直接识别词类,因此词类关系——特别是动词和名词的关系——极为复杂。汉语的动名两范畴边界模糊,存在大量兼类词。复杂的动名关系在本体研究(许群爱、邓云华,2024)、语言教学(朱志平,2013)、语言处理(杨丽姣等,2019)等领域引发了诸多关注。动名兼类词、动词、名词间的关系仍需要进一步的思考。

学者们对汉语的动名问题做了详细探讨。沈家煊(2007)提出“名动包含说”,系列研究建立起了一个动词包含于名词的汉语词类格局。但支持者有之,反对者亦有之。比如,陆俭明(2022)对比了名动分立和名动包含,指出后者解释能力有限,并且缺乏实际操作方案。沈家煊则先后援引施关淦文章、厘清名词的定义问题予以回应(沈家煊,2023a、2023b)。金立鑫(2022)质疑了名动包含说的逻辑基础,孙崇飞(2022)结合了汉语和印欧语的语言类型差别做了反驳。何清强、王文斌(2016)支持名动包含说,认可汉语的动词在语用上具有指称功能。吴义诚(2023)则提出批评,认为名词在句外一般具有指称性,但入句后则未必作指称语。虽仍未在动名格局上达成共识,但学界越发意识到语义在其中的重要性——动名词类范畴的模糊来自其语义的共通,因而有发生转用(名词化、动词化)的潜在可能(骆琳、穆柔云,2021)。已有研究一定程度上揭示了动名兼类的语义基础和表现,但仍存在一些不足,语义研究的理论和范式难逃其咎(沈家煊、乐耀,2013)。具体到动名问题上,主要症结在于:(1)过分着眼于微观,易陷入过拟合的僵局,即能较好解释所研究的特定结构,但推广到其他相关结构和整个系统时表现欠佳;(2)过度依赖语感,语料选择建立在因人而异的语感上,而非客观的使用频次、类型分布,有用典型例证以偏概全和以极端个案否定普遍特征的风险;(3)词类语义描写的一致性和形式一意义对应性差,同一问题不用或者不能用同一方法处理。这些问题期待研究范式和语言学理论的更新。

更新要建立在对话言事实(特别是动名词类相关语言事实)的正确认识上(陆俭明,2022)。那么,这个最基本的动名事实是什么样的呢?动词范畴和名词范畴内部并非均匀混合,有些成员的归属比较容易判断(如“吃”是动词,“苹果”是名词),有些则模棱两可(“收藏、出版、研究、学习”)。现有的词类体系基本都能摆准前者位置,而对后者的处理常常引起质疑。这是由于理论模型只是“典型代表”,“而‘语言事实’不会轻易就范逻辑上的‘完美’(简约)的理论”(詹卫东,2012)。想要把问题弄得更清楚,就不能只关注那些典型结构,更要清楚词的本质。关于词的本质,维特根斯坦(2005)曾提出了用法论,指出词的意义或本质就是它的用法。Harris(1954)和Firth(1957)等发展出了更具体的语言学理论假设,核心主张都在于用词的用法了解其意义。在这样的视角下,用法即语境关系的总和(刘海涛,1993),词的意义可以从词因使用产生的丰富语境关系把握。由于用法的多样,词的理解通常不是僵硬的非黑即白,黑白中间存在诸多灰色区域,使用者根据词使用时的语境选择出它最可能的意义(刘海涛,1993)。如此,动名关系可以理解为一个允许存在“灰色”的连续统,典型情况和非典型情况都能找到自己的位置(张伯江,1994;郭安等,2020)。

实际上,以用法论为代表的这些理论假设得到了数据驱动的实证。以词向量/嵌入模型(word vector/embedding model)为代表的语义处理技术在表示语义上表现惊人。又如,以 ChatGPT 为代表的大语言模型表现出了强大的语言理解能力和生成能力。词向量和语言模型处理语义的底层设计正是通过学习大规模文本中词丰富的上下文了解其语义。人工智能领域的实践表明,用法论结合数据驱动有助于认识那些复杂问题的本质,以及解决那些其他方法难以解决的问题。

以上研究及发现启迪我们结合数据驱动范式和用法论探索动名关系。用法论能给形而下的数据驱动提供理论指导,数据驱动范式又给形而上的用法论提供了配套支持,数据驱动范式和用法论能为解决动名兼类问题做另一个角度的尝试。此外,结合用法论和数据驱动范式还能够为数智时代语言学研究转型提供参考。

本研究先介绍用法论的合理性,讨论以数据驱动范式实现用法论的必要性。然后,在真实语料库的基础上,运用所述理论和方法,探索动词、名词、动名兼类词的关系,并以前人微观研究中的专家知识检验本研究提出的动名关系模型,本研究谨为更可靠的新范式和新理论建设抛砖引玉。

二 用法论、数据驱动与词向量

获取语义的路径大致可以分为基于规则与理性、基于经验与实证。在计算语言学语义表示任务的实践检验中,依赖于语义分解的理性主义方法,如逻辑推导、义素分析,愈发力不从心。逻辑语言面向于真值问题,力求精确,但自然语义通常是不精确的,逻辑语言对精确的追求可能与语义本身的模糊背道而驰。加之表达力上的劣势,更难以反映出自然语言的真实。正如叶姆斯列夫(2006)所言,包括逻辑语言、数学语言在内的其他语言可以完整转译为日常语言,但日常语言无法完整转译成其他语言。日常语言没有专门的目标,可以为任何目的服务,而其他语言都是有专门目标的,二者之间并不是对等的。理性主义是“死”的,适应语义灵活、模糊的能力有限,处理不可分割的语义时,即使分解同一对象,也难以找到统一、完整的标准,可能无法还原语言真实的面貌。

带着对这些问题的反思,经验主义和联结主义在二十世纪九十年代和二十一世纪初的两场计算语言学革命中回归了。反思的结果照应了维特根斯坦(2005)的“用法论”,用法论选择从词外在的真实使用获取它的意义,词的语境是直接的,不需要创造元语言转译,也就碰不到语义分解面对的那些难题。这一次的回归以大规模语料库和强大算力为基础,数据驱动范式有效保证了理论和算法的落地。

于是,具有强大语义表示能力的词向量/词嵌入模型出现了。词向量模型把词表示为同现词频组成的向量,因此词出现的概率就和它前面的词联系起来了,通过条件概率就能预测下一个词。词出现的概率越近似,其语义也就越接近。如此朴素的思想,经过了数据驱动的加持,就可以表示出丰富的自然语义,甚至还能表示出难以用其他方法获取的百科知识(Grand et al., 2022)、社会偏见(Garg et al., 2018)。然而,词向量模型也具有基于神经网络的模型的通病,维度和特征难以被解释。一些词向量模型将分布语义学(Harris,

1954; Firth, 1957) 作为后验证明。尽管其底层设计确实与分布语义学十分相关, 但它们的算法其实并不完全符合 Harris (1954) 的论述。另一方面, 词向量模型依赖于海量的数据, 数据量不足会严重损伤模型质量。这个现实说明了两个问题: (1) 传统语言学理论很难解释词向量模型, 更不可能像物理学指导工程学那样指导其发展; (2) 分布语义学为代表的语言学理论对解释和改进词向量模型具备潜力, 为数智时代的语言学研究何去何从提供参考。

Harris (1954) 把分布语义学的规则概括为三点。首先是作为基础规则的偏序 (partial ordering on words), 也称之为“算子—论元约束 (operator-argument constraint)”, Harris 的解释是“词序列何以表达词间的固定语义关系”。实际上说的就是语言层级结构, 比如“羊吃草”中“吃”作为谓词要比“羊”和“草”更“高级”。其次是似然 (likelihood), 即论元结构中的谓词会开辟需要论元填充的空位, 填补空位的论元有概率上的差别。比如“睡觉”会开辟一个空位, 这个空位需要名词性成分填补, 在“睡觉”的主语位置上出现“我”“张三”“狗”的概率显然比出现“石头”“树”“关系”要高。这种概率上的差异也是重要的约束。最后是简化 (reduction), 即把复杂的句子尽可能地拆分为几个完整论元结构, 再把无关成分剔除。比如“他数着星星就睡着了”, 可以拆分出两个完整论元结构: “他数星星”“他睡着”。“着”“就”了”被剔除。简化可以使论元结构更加清晰。

那么这三条规则在词向量模型中是如何落实的呢? 似然被落实得最充分, 词同现概率是词向量的基础。有的词向量模型会去除虚词, 这是一种类似于简化的操作。然而最重要的偏序却没有得到应有重视。语言具有层级结构, 不仅有线性处理, 还有非线性处理 (沈家煊, 2023c), 这导致了词并不总是和邻词建立联系。刘海涛 (2022) 指出同现关系实际上只有 50% 左右是句法依存关系, 从语言学角度来看, 同现关系只能覆盖一半用法, 仍有 50% 左右的信息对语义表示和理解可能是没有帮助的。因而, 在不考虑其他因素时, 词向量取得的成功来自与同现关系重叠的那一部分句法依存关系。这意味着, 如果把依存关系完全地纳入考虑范围, 就有可能进一步改善语义处理的效果。

依存关系是依存语法的核心, 它是两个词之间不对称的带标签的关系。依存关系与同现关系一样, 一个关系只发生在两个词之间, 因而两种关系具有可比性。经依存分析的例句如图 1, 依存关系可以发生在相邻词间, 如“这”和“是”间的 subj/ 主语关系; 也可以发生在非相邻词间, 如“是”和“例子”间的 comp/ 补足语关系。




图 1 依存句法树示例^①

Masito (2022) 用依存关系代替同现关系构造了词向量, 语义表示能力得到了显著提升。虽然由于使用了神经网络模型, 得到的词向量同样难以解释, 但也足以证明偏序原则或依存关系对语义表示的重要性。强可解释性的词向量被预期为所有特征都有语言学意义, 依存关系的标签为此提供了可能。

刘海涛、冯志伟 (2007) 提出的概率配价模式理论能快速构造出这样的词向量。概率配价模式已经在本体研究 (高松, 2010)、语言习得 (郝瑜鑫等, 2021)、类型学 (阎建玮、

刘海涛, 2023)等领域得到广泛应用。词或者词类的概率配价模式如图 2 所示。实线矩形为词或词类, 上方的 G_1 、 G_2 、 G_3 、…… G_{n-2} 、 G_{n-1} 、 G_n 是支配该词或词类的词或词类; 下方的 D_1 、 D_2 、 D_3 、…… D_{n-2} 、 D_{n-1} 、 D_n 是从属于该词或词类的词或词类。箭头代表依存关系, 上面的标签代表依存关系类型及其概率。取词或词类为行, 做支配词和从属词时的依存关系为列, 对应概率为值, 就能得到一组可解释的词向量。




图 2 词或词类的概率配价模式

接下来, 这种词向量将用于探索动名关系以及它们的布局模式。为了区别, 一般意义上的词向量被称作同现词向量, 本文所主要使用的词向量被称作依存词向量。

三 数据驱动的动名兼类研究

词向量将词的语义表示为连续的向量, 这暗示了动名语义的连续。动词语义能渐变过渡为名词语义, 反之亦然。实际上, 这种动名连续统假设由语言学家提出, 张伯江 (1994)、郭安等 (2020) 都曾做过构造动名连续统的尝试。但这些连续统里没有动名兼类词的位置, 不使用起来精细地观察动名关系。还有一些类似于连续统的探索, 如袁毓林 (2005) 曾把词类典型的分布特征作为词类范畴的属性, 根据经验给予每个属性权重, 进而计算出词对名词或动词的隶属度。然而分布特征难以穷尽, 权重的获取也依赖于主观经验。

当前已有少数基于词向量的动名关系研究。施建军、周瓴 (2023) 用同现词向量研究了“N 的 V”结构中动词的性质。陆旭等 (2024) 用同现词向量计算了动名关系。然而, 由于同现词向量的特征缺乏明确的语言学解释, 其分析结果不易与词类用法建立可靠关联。尽管这些研究存在一些不足, 但仍然显示出词向量在动名兼类问题中的强大潜力。本部分将基于大规模标注语料构造的词向量实证动名连续统, 使用经过检验的专家知识以及参照词向量验证其可信度, 随后再观察那些从微观视角难以观察到的动名关系宏观模式。

(一) 资源及预处理

本研究使用的数据集是来自 Surface Syntactic Universal Dependencies (SUD) 的现代汉语树库 GSD、HK 和 PUD。SUD 是基于句法原则标注的语料库资源, 常被用于自然语言处理和语言学研究, 所选树库共计 7001 句, 规模为 154580 词。SUD 中依存关系标签的颗粒度非常细, 为了更贴近语言学传统的句法成分, 具有相同标记的依存关系被合并为粗颗粒的新依存关系, 操作原则见附注。这样的操作便于观察和解释词和词类的特征, 也能给数据降维, 改善数据稀疏问题。

首先统计每个词型拥有的所有词类标签, 将其中只有名词和动词的记为动名兼类词, 只有动词的记为动词, 只有名词的记为名词。这样的筛选是为了免除其他词性用法的干扰, 降低噪声。然后经人工校验, 剔除因字形相同而导致的误差。由于频次太低的词展现的

用法不够全面,只有频次大于 10 的词纳入统计范围。标注的词类信息仅作为标签,而不用用于词分类或聚类的过程。经统计,符合条件的动名兼类词 217 个,动词共计 139 个,名词共计 455 个。向量自依存关系而来,依存关系是经过了检验的用法知识,也是动名实验的依据。接下来按照词和词类的概率配价模式构造出动词、名词、动名兼类词的词向量和动词、名词的词类向量。最后,量化词(类)向量间的关系。余弦相似度是最常用的手段,常用于文本相似度比较、语义关系分析等任务,计算方法可见于公式(1):

$$Similarity(A,B)=\frac{A\cdot B}{||A||\times ||B||}=\frac{\sum_{i=1}^n(A_i\times B_i)}{\sqrt{\sum_{i=1}^nA_i^2}\times \sqrt{\sum_{i=1}^nB_i^2}}$$

(1)

公式(1)中,和是两个对比对象的向量,是向量的第个值,是向量的第个元素。在动名兼类问题里,作比较的向量是词向量和词类向量,二者的余弦相似度越大,就说明该词与该词类的关系越密切,反之越疏离。换言之,余弦相似度是计量词与动词词类和名词词类间关系的指标。

(二) 结果

经过统计,动词词类、名词词类的概率配价模式如表 1。

表 1 动词词类和名词词类的概率配价模式中各依存关系的比率

依存关系	动词类		名词类	
	做支配词	做从属词	做支配词	做从属词
subj	18.35	1.21	1.14	20.38
root	0	17.71	0	0.63
comp	44.19	57.94	0.12	37.27
mod	22.70	14.73	60.48	23.97
udep	8.43	0	7.88	1.26
appos	0.08	0.03	2.95	1.26
cc	0.33	0	3.14	0
clf	0	0	5.40	1.52
compound	0.56	2.00	6.87	8.30
conj	1.01	1.71	4.53	4.32
det	0	0	6.42	0
discourse	0.80	0	0	0
dislocated	0	0.10	0.10	0
flat	0	0	0.15	0.28
orphan	0	0	0	0
parataxis	3.38	4.48	0.79	0.47
reparandum	0	0	0	0
vocative	0.10	0	0	0.31

为了方便观察,表 1 数值为依存关系所占百分比。如表 1 所示,动词主要作 comp、subj、mod 中的支配词(受宾语、主语、修饰语修饰);主要作 comp、root、mod 中的从属词(作宾语、谓语、修饰语)。名词主要作 mod 中的支配词(受修饰语修饰);主要作 comp、mod、subj 中的从属词(作宾语、修饰语、主语)。与前人结果(高松,2010;高松等,2010)一致。

再计算出所有的单个名词、动词、动名兼类词的的概率配价模式,提取出对应的向量。借助公式(1),算出单个的词与动词词类、名词词类的相似度。以名词相似度为横轴,动词相似度为纵轴绘制散点图(见图3)。图3中动词和名词各自聚成一团,动名兼类词则连接了两个词类,大致得到了一个前人定性研究所预期的连续统模式。在进一步观察动名宏观模式之前,我们先通过三重验证检验结果的可信度。

1. 检验一:专家微观知识

前人的定性研究发现了动名连续统在句法或语义层面的一些微观特征。如果连续统中能够观察到这些特征,那么可以认为其能够如实反映动名关系。值得注意的是,检验的目的不在于验证这些已被发现的微观模式的有效性,而在于检验基于依存词向量构建的动名连续统的可信度。

从句法角度看,动词和名词的语法功能虽然各有特色,但也存在重叠之处。根据表2统计出的概率配价模式可知,动词的主要功能包括充当宾语、谓语、修饰语,以及带宾语和被修饰;而名词主要用作宾语、修饰语和主语,也可以被其他词修饰。比较这些主要功能可见,动词的独有主要功能包括充当谓语和带宾语,而名词的独有主要功能是担任主语。独有主要功能是观察连续性的良好窗口。借助真实的语言使用,处在动名连续统里的词可以游移向两端,随着游移的程度加深,就会越多地表现出动词或名词的独有主要句法功能。张伯江(1994)、郭安等(2020)的研究支持了这样的观点。接下来,要确认动名连续统是否能表现出这些句法微观特征。

经相关性检验,动名连续统的确能表现出这些特性:带宾语的的概率与动词相似度呈正相关($r_V=0.793, p_V<0.01$),与名词相似度呈负相关($r_N=-0.583, p_N<0.01$);充当谓语的的概率也是如此($r_V=0.657, p_V<0.01$; $r_N=-0.478, p_N<0.01$);而充当主语的的概率与动词相似度呈负相关($r_V=-0.422, p_V<0.01$),与名词相似度呈正相关($r_N=0.630, p_N<0.01$)。这说明动名连续统在句法层面上是成立的。

其次是语义上的连续。动词和名词的基本语义分工虽然比较明确,但也存在相互转化的可能。Langacker(1987)认为名词指的是事物,即相互联系的实体,动词指的是随时间而变化的过程。张伯江(1994)进一步指出名词表达事物,空间性强可计数,动词表达动作,时间性强可延续。郭安等(2020)指出了名转动的语义过程为“实体—属性化—状态化—动作化”。这些结果共同表明动名的语义差异表现在对空间和时间的不同偏好上。

时间性的句法表现是带动态助词“着”“了”“过”,空间性的句法表现是受名量词修饰(张伯江,1994)。对动词、名词和动名兼类词的统计显示,带动态助词的的概率与动词相似度呈正相关($r_V=-0.580, p_V<0.01$),与名词相似度呈负相关($r_N=-0.124, p_N<0.01$);受名量词修饰的概率与动词相似度呈负相关($r_V=-0.223, p_V<0.01$),与名词相似度呈正相关




图3 词的动名相似度

($r_N=0.447, p_N<0.01$)。与前人研究结果一致,动名连续统在语义层面上也成立。

2. 检验二:词典个案对比

以《现代汉语词典(第七版)》(以下简称《现汉》,中国社会科学院语言研究所词典编辑室,2017)为代表的词典中标注了词类信息,可以在一定程度上为词类问题提供参考。对于有多种词性标注的词,标记的前后实际上反映了该词多种用法的常用程度序列(周荐,2016)。因此,词类标签的先后可以视作兼类词更倾向于动词还是名词的参考。

图3中的动名相似度仍然是个二维特征,为了更直观地展示词接近动词还是名词,我们将其调整为了一维特征,计算公式如下:

$$\text{调整动名相似度} = \text{动词相似度} - \text{名词相似度} \quad (2)$$

调整动名相似度越小该词就越接近名词,越大则越接近动词,越接近0就越难以辨别词类。

本节选取了14个常用或常见于兼类研究的词,对比它们的调整动名相似度与《现汉》中词性标注的顺序,观察其一致性。如果具有一致性,则可以认为连续统可信。14个兼类词的调整动名相似度及其词性标注见表2。

表2 词典词性标注情况

词	词性	调整动名相似度	词	词性	调整动名相似度
保险	名动	-0.49	移民	动名	-0.00
游戏	名动	-0.42	发言	动名	0.01
关系	名动	-0.30	学习	动	0.10
生活	名动	-0.23	经历	动名	0.19
来源	名动	-0.12	主张	动名	0.29
出版	动	-0.02	希望	动名	0.41
研究	动	-0.01	帮助	动	0.48

调整动名相似度显示,14个兼类词大致可以分为3类:偏好于名词性用法(“保险、游戏、关系、生活、来源”)、无明显偏好(“出版、研究、移民、发言”)、偏好于动词性用法(“学习、经历、主张、希望、帮助”)。词典标注显示,14个词都有动词词性标注,偏好名词性用法的词把名词标注在动词前,偏好动词性用法的词把动词标注在名词前,或者不出现名词标记。而无显著偏好的词的标注比较复杂,但都没把名词放在动词前。

调整动名相似度结果与词典结果基本保持了一致。“保险、游戏、关系、生活、来源”这些偏好名词性用法的兼类词更多地以名词性用法出现,符合语感。再来看“出版、研究、移民、发言”这4个没有显著偏好的兼类词。其中,“出版、研究、学习”是动名兼类研究里常见的例词,是最难判断词性的几个个案,结果表明这种困境很可能来自它们本身的无显著偏好(“学习”虽然是偏好动词性用法的兼类词,但其调整动名相似度仍比较接近于0)。最后,“经历、主张、希望、帮助”更多以动词性用法出现,基本符合语感。

此外,表2有几个个案标注与调整动名相似度的结果有一些偏差——“出版、研究、学习、帮助”未标注名词。“出版、研究、学习”无显著偏好,“帮助”显著偏好动词。“出版、研究、学习”这类难以处理的动名兼类词都被标注为动词,调整动名相似度近似的“发言”

却兼具动名,这表明《现汉》的标注一致性仍有进步空间。“帮助”虽然特别偏好动词性用法,但其名词相似度其实也很高,标注时也不应顾此失彼。王仁强(2013)指出这些偏差与要求兼类要少的“简略原则”相关,认为对“简略原则”的过分强调忽略了语言的真实使用,因而难以正确指导词典词性标注。《现汉》的词性标注应建立在真实语料的基础之上,编纂和修订应与时俱进。本节结果与《现汉》标注有较高的一致性。

3. 检验三:参照同现词向量

同现词向量的最大好处是,只要保证了数据规模,就能如实反映语言的面貌。因此尽管它难以解释,但可以作为依存词向量结果的客观参照。陆旭等(2024)的实验表明,这类词向量能够识别出动名区别,能够充当参照。通过对比两种词向量的匹配度,就能够检验基于依存词向量的动名连续统的可信度和有效性。

本节使用的参照同现词向量来自 FastText 多语言预训练模型中的汉语模型,维度为 300,其语料来自维基百科和 Common Crawl,共计约 1909 万词。该词向量在类比任务中表现良好(Grave et al., 2018),具有较为强大的语义表示能力。

取动词、名词、动名兼类词的同现词向量,以 t-SNE 算法降至二维并可视化,结果见图 4,代表典型动词的蓝点聚集于右上方,而代表典型名词的黄点则分布得有明显区别。

代表典型动名兼类词的绿点,分布跨越了典型动词和典型名词的区域,并且与典型动词的重叠更加广泛。图 3 和图 4 数据点分布的差异是由于横轴纵轴表示信息的差异。图 3 的横纵轴是词的动名相似度,图 4 的横纵轴由降维得来,其语言学意义不得而知。但词类分布模式是基本一致的,也就是说,依存词向量在动名宏观




图 4 基于大规模未标注文本训练的词向量表现出的词类分布模式表示上是有效的。

4. 汉语的宏观动名分布模式分析

三重验证显示,依存词向量表示出的动名宏观模式具备一定的可信度和有效性。本节将详细分析动名关系的宏观模式。

动词和名词表现出明显的范畴化。图 3 中,动词的动词相似度显著大于其名词相似度($p < 0.01$),名词的名词相似度显著大于其动词相似度($p < 0.01$)。动名兼类词里有 91.2% 动词相似度大于 0.5, 90.8% 名词相似度大于 0.5, 动名兼类词与动词和名词的相似程度绝大多数都很高,兼具动词和名词的特点。动词和名词明显聚合成了两个类。并且,动词/名词内部的差异也被明确地反映出来——尽管都是动词/名词,但它们仍然存在动词/名词相似度上的不同。另一方面,动名兼类词散布在动词、名词和中间区域上。经相关性检验,

动名兼类词的动词相似度和名词相似度呈中度负相关($r=-0.424, p<0.01$),这意味着若动名兼类词的动词相似度越高,其名词相似度就越低。换言之,动名兼类词越接近动词就越可能远离名词,反之亦然。

动名连续统两端地位不平等。动名兼类词是游移在动名两范畴边缘的词,其调整动名相似度的变化能够反映动名连续统间的连续过程。计算所有动名兼类词的调整动名相似度,根据大小排列顺序的时序(见图5),连续统全局结




图5 一维化的动名连续统

果显示,动名兼类词中有58.5%调整动名相似度大于0,更接近动词,41.5%调整动名相似度小于0,更接近名词。整体来看,动名兼类词的主流是偏好动词性用法,符合沈家煊(2007)所说的“动词名用”和“名词动用”不对称现象。陆旭等(2024)也用类似方法观察到了动词优势,但具体数值有所差异。这可能与操作细节和词的选取有关,“动词名用”和“名词动用”的不对称程度的具体分布仍然需要进一步研究。名动格局对动词性用法的偏向可能是汉语的一个类型特点,调整动名相似度可以作为反映词类类型学特点的一个指标。

动词和名词内部也表现出范畴化。动词和名词内部成员也可以计算出动名相似度,绘制其直方图(见图6)。为了更加清楚地表现出词类内部的范畴化,使用高斯平滑算法抑制数据噪声。




图6 调整动名相似度的概率密度

图6展示了不同词类在调整动名相似度上的概率密度分布情况。结果表明,名词和动词的分布曲线相对陡峭,而动名兼类词的分布则较为平缓。这一差异再次印证了名词与动词作为基本词类的范畴化特征,以及兼类词在类别边界间跨越的中介性质。值得注意的是,名词与动词的分布均呈现出明显的双峰形态,表明两者在该维度上存在一定的内部结构分化。进一步观察可见,名词双峰的高度有明显差异,这说明名词内部可能包含一个具有强名词属性的主要子类以及一个较弱子类。相比之下,动词的双峰高度接近,暗示其内部可能存在两个在动词属性上有所差异的子类。

(三) 讨论

统计结果表明,汉语的动词和名词呈现出连续统模式。连续统模式并非肯定或者否

定“名动包含说”。动词(或者叫“动态名词”)和名词(或者叫“静态名词”)有显著差别,但这个差别中又是蕴含着共性的。差别是不足以成为动名词类分立的证据,共性是不足以成为“大名词”的基础,都值得商榷。从连续统模式来看,明显的范畴化说明动词和名词大体上作为两个范畴而存在,但内部以及兼类词的非均质又暗示了词类范畴化是相对而言的。因此,“名动包含说”应当更加重视动名词类间的显著区别,“名动分立说”则须更加关注两词类间边界的模糊。

词类不是先验范畴,而是在使用中涌现出来的后验范畴。在使用中,概念实现为具体的词,这些词对不同用法各有偏好,偏好相似的词聚合成类。这样的过程决定了词类不是界限分明的,有的词“合群”,有的不那么“合群”。想精确把握词或词类间的关系,不应只谈“能不能这么用”,更要谈“有多少可能这么用”。吴义诚(2023)曾指出“语言学研究要坚持‘两眼齐观’的原则,既不能侈谈人类语言的共性而忽略一种语言的个性,又不能一味夸大一种语言的个性而忽视人类语言的共性”。化用到词类问题里也颇有道理:既不能侈谈动词名词的共性而忽略其个性,又不能一味夸大一种词类的个性而忽视动词名词的共性。

本研究也探索了语言学理论知识在数智时代如何发挥作用。同现词向量模型在语义表示任务中表现良好,但可解释性差、对数据规模的依赖过高。可解释性差的模型只是个“黑箱”,质量评估几乎只能通过语义类比等任务,也无法解析其内部的结构关系,更难以能动地调整模型。语言学要为语言现象提供解释,这个问题显然无法回避。模型对超大规模数据和强大算力的依赖,一定程度上是为了获取那些已经被语言学家们验证过的知识,事实上造成了资源浪费。检验三证明经验知识能帮助词向量使用较小规模语料就达到类似效果,这表明将经过检验的知识提前输入模型就可能节省数据和算力资源,甚至提升模型效果。Masito(2022)曾用句法距离取代窗口跨距,所得词向量的语义表示能力有明显提升,能够佐证以上观点。

当然,就细微语义的表示而言,本文使用的依存词向量远比不上同现词向量。这既来自数据量间的差距,也是由于缺乏神经网络模型的加持。但至少依存词向量能够表示出动名关系这种宏观语义,还能够将其与微观知识可信地联系起来,于本文研究目的而言已经足够了。理想的词向量模型应当既有强大的语义表示能力,又具备良好的可解释性,还能减少对超大规模数据的依赖。语言学理论在提升模型可解释性和降低数据算力依赖上仍具备潜力,Masito(2022)等研究具备良好的借鉴价值。

四 结语

本文梳理了用法论和数据驱动的理论基础,并以数据驱动范式探索了动名范畴的连续统模式。研究表明,词类是词因用法形成的动态类,没有显著的边界,不同词类范畴可以相互渗透。针对汉语动名关系,数据驱动能帮助把微观研究成果放大到全局,能用更科学的频次取代感性的语感,还能一定程度上改善处理语义时的同一性问题,为处理动名兼类难题提供新的思路。研究结果也显示,经过检验的语言学知识对语言模型降

低数据规模依赖和提高计算效率是有效的。在数智时代,语言学能够以更加积极的姿态参与到语言智能的实践中。本文的探索也能够为语言学在数智时代有所作为提供一定参考。李国杰院士曾指出,“数据密集型科学研究已上升到与科学实验、理论分析、计算模拟的科学研究‘第四范式’……大数据……对社会科学的变革意义与伽利略首次将望远镜指向太空对天文学的意义一样重大”。^②这个“变革意义”,来自数据驱动对复杂问题本质的敏锐洞悉。只有更真切、更精确、更全面地了解到问题的“缘之所起”,才可能更好地解决它——这对处理那些以动名兼类为代表的“老大难”问题至关重要。

当然,数据驱动处理语义是语言学研究的新兴领域,本文也只是做一些探索,因此难免会有所偏颇,如缺乏神经网络技术参与后的情况分析,未涉及其他相关词类(如形容词)的影响。

[附 注]

① 本文所用的依存关系来自调整后的 SUD,对 SUD 的依存关系处理如下:

(1) root、parataxis、dislocated、appos、clf、det、cc、discourse、orphan、reparandum、flat、vocative 保持不变;

(2) subj@pass、subj 合并为 subj; comp:obj、comp:obj@rel、comp:obj@x、comp:obj@adv、comp:obl@x、comp:obl、comp:obl@agent、comp:aux、comp:aux@passive、comp:obj@loc、comp:obj@prt、comp:obj@periph 合并为 comp; mod@relcl、mod@tmod、mod、mod@df 合并为 mod; conj:emb、conj 合并为 conj; udep@mod、udep@patient、udep 合并为 udep; compound、compound@ext、compound@vv、compound@dir、compound@vo 合并为 compound。

调整后的依存关系标签及其顺序: subj、root、comp、mod、udep、appos、cc、clf、compound、conj、det、discourse、dislocated、flat、orphan、parataxis、reparandum、vocative。

考虑到篇幅,附表1仅为我们合并后的关系及例句,更详细的关系及例句可见于SUD官网(<https://surfacesyntacticud.github.io/guidelines/u/>)。

② 见于李国杰院士为《可视化未来:数据透视下的人文大趋势》(艾登·米歇尔著,王彤彤等译,浙江人民出版社,2015)所作序言。

[参考文献]

- [1] 高松.基于依存树库的现代汉语名词语法功能的计量研究[J].华文教学与研究,2010,(2).
- [2] 高松,颜伟,刘海涛.基于树库的现代汉语动词句法功能的计量研究[J].汉语学习,2010,(5).
- [3] 郭安,张全生,邢欣.汉语名词转动词的论元指称义弱化研究[J].语言与翻译,2020,(1).
- [4] 郝瑜鑫,王雪琳,刘海涛.基于句法标注语料库的汉语中介语动词配价发展计量研究[J].语言文字应用,2021,(1).
- [5] 何清强,王文斌.空间性特质与汉语的个性特点——从离合词的成因谈起[J].外国语(上海外国语大学学报),2016,(1).
- [6] 金立鑫.“名包动”理论的逻辑问题[J].外国语(上海外国语大学学报),2022,(1).
- [7] 刘海涛.维特根斯坦语言哲学对计算语义学的影响[A].计算语言学研究与应用[C].北京:北

- 京语言学院出版社,1993.
- [8] 刘海涛,冯志伟.自然语言处理的概率配价模式理论[J].语言科学,2007,(3).
- [9] 刘海涛.依存关系与语言网络[M].北京:科学出版社,2022.
- [10] 陆俭明.再议“汉语名动包含说”[J].外国语(上海外国语大学学报),2022,(5).
- [11] 陆旭,Aleksandr Mitkov,冉启斌.从词向量计算看汉语名词和动词的关系[J].语言教学与研究,2024,(3).
- [12] 骆琳,穆柔云.从物性结构看工具类名词的动词化现象[J].语言文字应用,2021,(3).
- [13] 沈家煊.汉语的动词和名词[J].汉藏语学报,2007,(1).
- [14] 沈家煊,乐耀.词类的实验研究呼唤语法理论的更新[J].当代语言学,2013,(3).
- [15] 沈家煊.评施关淦“现代汉语的向心结构和离心结构”[J].外国语(上海外国语大学学报),2023a,(5).
- [16] 沈家煊.名词的定义问题[J].现代外语,2023b,(3).
- [17] 沈家煊.ChatGPT,赵元任,新文科——一个语言学家的思考[J].中国语言战略,2023c,(1).
- [18] 施建军,周瓴.基于词向量的汉语“N的V”结构研究——兼与日语「NのV」结构比较[J].外语电化教学,2023,(2).
- [19] 孙崇飞.名动包含理论存在逻辑问题吗?[J].外国语(上海外国语大学学报),2022,(5).
- [20] 王仁强.现代汉语兼类问题研究——兼评索绪尔语言学思想的重要价值[J].外国语文,2013,(1).
- [21] 维特根斯坦.哲学研究[M].陈嘉映译,上海:上海人民出版社,2005.
- [22] 吴义诚.名词和动词[J].外国语(上海外国语大学学报),2023,(5).
- [23] 许群爱,邓云华.英汉动工具名词带宾构式的认知对比研究[J].语言文字应用,2024,(4).
- [24] 阎建玮,刘海涛.基于高频句法关系依存方向的语序类型计量研究[J].语言文字应用,2023,(2).
- [25] 杨丽姣,肖航,刘智颖.《信息处理用现代汉语词类标记规范》修订方案[J].语言文字应用,2019,(3).
- [26] 叶姆斯列夫.叶姆斯列夫语符学文集[M].程琪龙译.长沙:湖南教育出版社,2006.
- [27] 袁毓林.基于隶属度的汉语词类的模糊划分[J].中国社会科学,2005,(1).
- [28] 詹卫东.从语言工程看“中心扩展条件”和“并列条件”[J].语言科学,2012,(5).
- [29] 张伯江.词类活用的功能解释[J].中国语文,1994,(5).
- [30] 中国社会科学院语言研究所词典编辑室.现代汉语词典(第7版)[Z].北京:商务印书馆,2017.
- [31] 周荐.语文词典义项设立的专门与顺带——外来义项增列模式探讨[J].语言科学,2016,(3).
- [32] 朱志平.汉语二语教学中词汇计量的维度[J].语言文字应用,2013,(2).
- [33] Firth,J.R.A synopsis of linguistic theory, 1930-55[A]. *Studies in Linguistic Analysis (Special Volume of the Philological Society)* [C]. Oxford: Basil Blackwell, 1957.
- [34] Garg,N.,Schiebinger,L.,Jurafsky,D.,& Zou,J.,Word embeddings quantify 100 years of gender and ethnic stereotypes[J]. *Proceedings of the National Academy of Sciences of the United States of America*, 2018,(16).
- [35] Grand,G.,Blank,I.A.,Pereira,F.et al.Semantic projection recovers rich human knowledge of multiple object features from word embeddings[J]. *Nature Human Behaviour*, 2022,(6).
- [36] Grave,E.,Bojanowski,P.,Gupta,P.,et al.Learning word vectors for 157 languages[A]. *Proceedings*

of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)[C].

European Language Resources Association, 2018.

- [37] Harris, Z.S. Distributional structure[J]. *Word*, 1954, (2-3).
- [38] Langacker, R.W. Nouns and verbs[J]. *Language*, 1987, (1).
- [39] Maisto, A. Extract similarities from syntactic contexts: A distributional semantic model based on syntactic distance[J]. *Italian Journal of Computational Linguistics*, 2022, (2).

附录 依存关系及其示例

#	依存关系	例句
1	subj (主语)	<u>他</u> <u>是</u> 我男朋友
2	root (根)	他 <u>是</u> 我男朋友
3	comp (补足语)	他是 <u>我</u> <u>男朋友</u>
4	mod (修饰语)	这个比例一直在 <u>稳步</u> 上升
5	udep (属性或属格)	<u>于</u> 2013 年 <u>通过</u> 了投票权利法案
6	appos (同位语修饰)	从 <u>英镑</u> 贬值这一 <u>事件</u> 中获利
7	cc (并列词)	蒙古 <u>和</u> 中国
8	clf (量词)	两 <u>个</u> 人
9	conj (连词)	该方案通过 <u>赞助</u> <u>和</u> <u>广告</u> 来盈利
10	compound (复合词)	<u>美</u> 元
11	det (限定语)	<u>这</u> 部 电影
12	discourse (话语标记词)	吃肉 <u>是</u> 有罪 <u>的</u>
13	dislocated (脱位词)	他的 <u>死</u> 疑点 <u>重重</u>
14	flat (扁平固定搭配)	位于 <u>la conte</u> 区内
15	orphan (孤词)	北京外城共有七门, <u>南面</u> <u>三</u> <u>门</u>
16	parataxis (并列式)	他的父亲 <u>去世</u> , 母亲对他十分 <u>溺爱</u>
17	reparandum (失语)	<u>就</u> - <u>就</u> 照你意思处罚
18	vocative (呼语)	<u>爷爷</u> , 你看

注: 例句中加下划线的两词具有对应行的依存关系, 加粗的词语是该关系中的从属词。其中, root 关系没有支配词。

(责任编辑 陈丽湘)